

Akademia Górniczo-Hutnicza im. Stanisława Staszica w
Krakowie

Wydział Informatyki

RAPORT KOŃCOWY PROJEKTU

Prognozowanie zagrożeń dla zdrowia publicznego
na podstawie zbioru danych NHANES

Autorzy:

Oliwia Łośko

Patrycja Puskarczyk

Kraków, 2026

Spis treści

1	Cel projektu	2
2	Część I: Predykcja występowania cukrzycy	2
2.1	Zbiór danych i przygotowanie	2
2.2	Modele	3
2.3	Wyniki dla analizowanych modeli	3
2.3.1	Macierze pomyłek i progi decyzyjne	3
2.3.2	Krzywe ROC oraz Precision-Recall	4
2.3.3	Istotność cech (SHAP)	6
2.3.4	Analiza lokalna (Waterfall Plot)	7
3	Część II: Wieloetapowa predykcja depresji – wpływ stylu życia i chorób współistniejących	8
3.1	Motywacja i ewolucja podejścia badawczego	8
3.2	Zmienna docelowa – Kwestionariusz PHQ-9	9
3.3	Zestawienie cech	9
3.4	Dobór architektury klasyfikującej – LR vs CatBoost	9
3.5	Wyniki dla obu eksperymentów	10
3.6	Istotność cech i interpretowalność (SHAP)	12
3.7	Weryfikacja literaturowa i analiza rozbieżności	14
4	Wnioski końcowe	15
4.1	Wnioski z Części I	15
4.2	Wnioski z Części II	16

1 Cel projektu

Celem projektu było wykorzystanie ogromnych, rzeczywistych zbiorów danych z amerykańskiego badania zdrowotnego NHANES (cykl 2017–2018) do oceny i predykcji kluczowych zagrożeń dla zdrowia publicznego. Ze względu na złożoność problemu, projekt został podzielony na dwie części.

Część I skupia się na sprawdzeniu, czy na podstawie wybranych parametrów klinicznych i możliwe jest precyzyjne przewidywanie występowania cukrzycy. Natomiast **Część II** dotyczy ewaluacji ryzyka wystąpienia depresji. Analiza ta przechodzi od prostych wskaźników stylu życia i warunków socjoekonomicznych, aż po weryfikację założeń literaturowych dotyczących wpływu wielochorobowości na zdrowie psychiczne.

W obu przypadkach istotnym problemem okazał się niezbalansowany zbiór danych - liczba osób chorujących zarówno na cukrzycę, jak i na depresję była znacznie mniejsza niż liczba osób zdrowych. W takiej sytuacji modele mogłyby osiągać wysoką dokładność nawet przy częstym przewidywaniu braku choroby, co nie oznaczałoby ich rzeczywistej skuteczności. Z tego powodu, podczas oceny modeli zrezygnowano z polegania na samej dokładności klasyfikacji, a większy nacisk położono na metryki lepiej opisujące wykrywanie przypadków pozytywnych, przede wszystkim Recall dla klasy 1 oraz ROC AUC.

2 Część I: Predykcja występowania cukrzycy

2.1 Zbiór danych i przygotowanie

Dane to 8 plików .xpt (format SAS) z różnych modułów NHANES (z cyklu 2017-2018), połączonych po kluczu SEQN:

- DEMO_J – demografia (wiek, płeć)
- BMX_J – pomiary ciała (BMI, obwód pasa)
- BPX_J – ciśnienie krwi
- GLU_J – glukoza na czczo
- DIQ_J – czy zdiagnozowana cukrzyca (zmienna docelowa)
- INS_J – insulina
- TCHOL_J – cholesterol
- TRIGLY_J – LDL/trojglicerydy

Usunięto braki danych i obserwacje gdzie DIQ010 nie było 1 ani 2. Zmienna docelowa: 1 = cukrzyca, 0 = brak. Podział 80/20 ze stratyfikacją.

Tabela 1: Cechy wykorzystane w modelach

Kod zmiennej	Opis
RIDAGEYR	Wiek
RIAGENDR	Płeć
BMXBMI	Wskaźnik BMI
BPXSY1	Ciśnienie skurczowe
LBXGLU	Poziom glukozy na czczo
BMXWAIST	Obwód pasa
LBXIN	Poziom insuliny
LBXTC	Poziom cholesterolu całkowitego

2.2 Modele

Wytrenowano cztery modele:

1. **LR – podstawowe cechy:** regresja logistyczna, 5 cech, `class_weight='balanced'`
2. **LR – rozszerzone cechy:** analogiczna regresja logistyczna, uwzględniająca dodatkowe cechy: obwód w pasie, poziom insuliny i cholesterolu całkowitego
3. **LightGBM + SMOTE:** gradient boosting na oversamplingowanych danych
4. **XGBoost + SMOTE:** analogicznie

Dla LR dane były standaryzowane (`StandardScaler`). Dla modeli drzewiastych standaryzacja nie jest potrzebna.

2.3 Wyniki dla analizowanych modeli


Tabela 2: Porównanie metryk modeli

Model	Acc.	AUC	Avg Prec.	F1 (mac)	Prec.	Rec.	F1
LR (pods.)	0.8699	0.9346	0.7991	0.7879	0.5304	0.8592	0.6559
LR (rozs.)	0.8721	0.9252	0.7919	0.7883	0.5327	0.8507	0.6552
LightGBM	0.9147	0.9350	0.7953	0.8301	0.6901	0.7313	0.7101
XGBoost	0.9147	0.9362	0.7685	0.8359	0.6753	0.7761	0.7222


2.3.1 Macierze pomyłek i progi decyzyjne

Analiza macierzy pomyłek pozwala ocenić skuteczność klasyfikacji chorych (1) oraz zdrowych (0):

- **Modele LR:** Regresja logistyczna (wersja podstawowa) charakteryzuje się bardzo wysokim wskaźnikiem *Recall* – pominięto jedynie 10 przypadków chorych. Odbywa się to jednak kosztem dużej liczby fałszywych alarmów (54 błędy typu *False Positive*).
- **LightGBM i XGBoost (próg 0.5):** Modele te wykazują znacznie wyższą precyzję niż LR. Redukują liczbę fałszywych alarmów o ponad połowę, zachowując przy tym stabilną wykrywalność przypadków pozytywnych.
- **Wpływ progów decyzyjnych:** Analiza wykresu 2 uwiadamia kluczowy kompromis diagnostyczny. Przy obniżonym progu (0.3) oba modele osiągają *Recall* powyżej 0.79. Z kolei podniesienie progu do 0.8 sprawia, że modele stają się zbyt zachowawcze, co skutkuje pominięciem niemal połowy osób chorych.



Rysunek 1: Macierze pomyłek dla modeli




Rysunek 2: Wpływ progów decyzyjnych na macierz pomyłek


2.3.2 Krzywe ROC oraz Precision-Recall

Wykresy ROC oraz Precision-Recall służą do oceny ogólnej zdolności modeli do separacji klas:

- **Krzywa ROC:** Wszystkie zaimplementowane modele osiągnęły wyniki $AUC \in [0.925, 0.936]$. Świadczy to o niemal idealnym szeregowaniu pacjentów według stopnia ryzyka wystąpienia choroby.
- **Krzywa PR:** Zauważalna jest przewaga regresji logistycznej w niskich zakresach czułości (*Recall*). Modele drzewiaste (LightGBM i XGBoost) wykazują jednak stabilniejszą precyzję w szerszym zakresie. Średnia precyzja (*AP*) na poziomie 0.77–0.80 potwierdza wysoką jakość predykcji.



Rysunek 3: Krzywe ROC dla modeli




Rysunek 4: Krzywe Precision-Recall

2.3.3 Istotność cech (SHAP)


Interpretacja modeli za pomocą wartości SHAP, pozwala zrozumieć czynniki wpływające na predykcję:

- **Dominacja glukozy:** Najważniejszą cechą jest poziom glukozy na czczo (**LBXGLU**), co jest spójne z praktyką kliniczną.
- **Kierunek wpływu:** Wykres `shap.png` pokazuje, że wysokie wartości glukozy, zaawansowany wiek (**RIDAGEYR**) oraz duży obwód pasa (**BMXWAIST**) drastycznie zwiększają prawdopodobieństwo diagnozy cukrzycy (punkty czerwone po prawej stronie osi).
- **Cechy drugorzędne:** Parametry takie jak poziom insuliny (**LBXIN**) czy płeć (**RIAGENDR**) wnoszą relatywnie mniej informacji do procesu decyzyjnego modelu.



Rysunek 5: Istotność cech

Wpływ cech na predykcję (wartości SHAP)




Rysunek 6: Wykres SHAP

2.3.4 Analiza lokalna (Waterfall Plot)

Wykres kaskadowy dla pacjenta nr 0 ilustruje działanie modelu na poziomie jednostkowym: Wartość bazowa $E[f(X)]$ wynosi ok. -2.7 . U tego konkretnego pacjenta czynniki takie jak niska glukoza (96) oraz relatywnie niski obwód pasa (82) obniżają wynik predykcji (kolor niebieski), co skutkuje bardzo niskim prawdopodobieństwem choroby ($f(x) \approx -5$). Obie architektury wykazują w tym przypadku wysoką spójność interpretacyjną.

Wyjaśnienie predykcji dla pojedynczego pacjenta



Rysunek 7: Wyjaśnienie predykcji dla pojedynczego pacjenta

3 Część II: Wieloetapowa predykcja depresji – wpływ stylu życia i chorób współistniejących

3.1 Motywacja i ewolucja podejścia badawczego

W przeciwieństwie do diagnozowania cukrzycy na podstawie wyników badań laboratoryjnych, predykcja problemów ze zdrowiem psychicznym opiera się na analizie złożonych czynników behawioralnych i społecznych. Tę część projektu zaprojektowano w sposób iteracyjny, przeprowadzając serię eksperymentów na zmodyfikowanych zestawach danych w celu opracowania skutecznego modelu predykcji depresji wśród osób dorosłych.

Aby ocenić możliwości modeli uczenia maszynowego w tym zakresie, proces podzielono na trzy badawcze scenariusze:

1. **Eksperyment 1** Zbiór cech w oparciu o artykuł naukowy [1]. Model testowano na całej populacji pacjentów.
2. **Eksperyment 2 (Warunek wielochorobowości):** Weryfikacja tezy literaturowej mówiącej, że pacjenci z diagnozą wielu chorób przewlekłych wykazują większe prawdopodobieństwo zapadalności na depresję. Zbiór z eksperymentu 1 zawężono wyłącznie do pacjentów, u których rozpoznano ≥ 2 choroby współist-

niejące (spośród m.in. nadciśnienia, astmy, cukrzycy, chorób wątroby, niewydolności serca).

3.2 Zmienna docelowa – Kwestionariusz PHQ-9

W obu badanych wariantach jako zmienna docelowa posłużył wskaźnik oparty na kwestionariuszu **PHQ-9** (Patient Health Questionnaire-9). Jest to powszechnie stosowane, standaryzowane narzędzie diagnostyczne składające się z 9 pytań, które pozwalają ocenić częstotliwość występowania objawów depresyjnych na przestrzeni ostatnich dwóch tygodni.

Każda z odpowiedzi punktowana jest w skali od 0 do 3, co pozwala uzyskać maksymalnie 27 punktów. Zgodnie z literaturą, a także na podstawie badań, którymi inspirowano się podczas selekcji cech, za punkt odcięcia definiujący grupę wysokiego ryzyka przyjęto wynik ≥ 10 . Próg ten jest rekomendowany ze względu na swoją wysoką skuteczność – charakteryzuje się czułością oraz specyficznością na poziomie 88% w detekcji dużej depresji (Major Depressive Disorder) [2]. Pacjentów spełniających ten warunek klasyfikowano do klasy 1 oznaczającej zwiększone ryzyko, a pozostałych przypisywano do klasy 0.

3.3 Zestawienie cech

Zestaw cech służących do predykcji ryzyka wystąpienia depresji został wybrany w oparciu o literaturę. Uwzględniono szeroki wachlarz zmiennych socjoekonomicznych, behawioralnych oraz klinicznych, wzorowany na wiodących badaniach nad depresją w bazie NHANES [1].

Warto zaznaczyć, że zmienne dotyczące diagnoz chorób przewlekłych posłużyły tylko jako filtr (kryterium włączenia) do wyodrębnienia w **Esperimentach 2** populacji z wielochorobowością. Nie są to natomiast bezpośrednio cechy wejściowe dla algorytmów. Pełne zestawienie atrybutów zaprezentowano w tabeli 3.

3.4 Dobór architektury klasyfikującej – LR vs CatBoost

Uwzględniając specyfikę zbioru danych (w tym występowanie wielu dyskretnych zmiennych kategoriowych oraz naturalne braki odpowiedzi ankietowych) jako docelową architekturę do optymalizacji wyłoniono algorytm **CatBoost**. Potrafi on dobrze interpretować zmienne tekstowe i toleruje braki (NaN), dzięki czemu ryzykowne imputacje danych, które mogłyby zniekształcić pierwotny sens zebranych ankiet, nie są konieczne. W celu rzetelnego sprawdzenia skuteczności modeli drzewiastych, każdy z eksperymentów porównywano z modelem klasycznej Regresji Logistycznej (z impu-

Tabela 3: Cechy uwzględnione w modelowaniu ryzyka depresji [1]

Kategoria	Zmienne (Kody NHANES)
Demografia	Wiek (RIDAGEYR), Płeć (RIAGENDR), Edukacja (DMDDEDUC2), Stan cywilny (DMDMARTL), Rasa/Pochodzenie (RIDRETH3), Wskaźnik ubóstwa (INDFMPIR)
Warunki życiowe	Status mieszkaniowy (HQ065), Ubezpieczenie zdrowotne (HIQ011), Bezpieczeństwo żywnościowe (FSD032A, FSD032B)
Styl życia i używki	Historia palenia (SMQ020), Palacze w gospodarstwie domowym (SMD460), Spożycie alkoholu (ALQ130), Twarde narkotyki (DUQ240)
Parametry kliniczne	Wskaźnik BMI (BMXBMI), Ciśnienie krwi (BPXSY1, BPXD11), Glukoza na czczo (LBXGLU), Hemoglobina (LBXHGB)
Dieta (Dzień 1)	Spożycie kofeiny (DR1TCAFF), Teobrominy (DR1TTHEO), Witamina B12 (DR1TVB12)

tacją k-najbliższych sąsiadów `KNNImputer` oraz standaryzacją), który we wstępnych testach na analogicznym zbiorze atrybutów dawał stosunkowo zadowalające wyniki (w tym wysoką czułość modeli).

3.5 Wyniki dla obu eksperymentów

W tabeli 4 zestawiono kluczowe metryki osiągnięte w obu wariantach eksperymentu. Hiperparametry algorytmów CatBoost i Regresji Logistycznej w scenariuszach B i C strojono z wykorzystaniem biblioteki *Optuna*.

Tabela 4: Porównanie modeli predykcji depresji: Populacja ogólna vs Wielochorobowość


Eksperyment	Dokładność	AUC	Czułość (1)	Precyzja (1)	Zbiór testowy
Eksperyment 1: Populacja ogólna					
Regresja Logistyczna	0.68	0.6971	0.62	0.17	$N = 408$
CatBoost	0.81	0.7165	0.49	0.24	$N = 408$
Eksperyment 2: Warunek wielochorobowości					
Regresja Logistyczna	0.58	0.5871	0.57	0.23	$N = 78$
CatBoost	0.68	0.6217	0.29	0.21	$N = 78$
CatBoost (+ SMOTE)	0.68	0.5647	0.07	0.08	$N = 78$

Analiza porównawcza pozwala na sformułowanie kilku istotnych wniosków.

- Wdrożenie cech zaproponowanych w artykule [1] na populacji ogólnej (Eksperyment 1) pozwoliło na bardziej stabilną predykcję. **CatBoost** osiągnął najwyższą zdolność separacji (AUC 0.7165), natomiast to model oparty na **Regrsji Logistycznej** osiągnął wyższą czułość (62% w stosunku do 49% dla CatBoosta). Dowodzi to, że w rzeczywistości istnieją silne zależności między statusem socjo-

ekonomicznym a ryzykiem depresji, z którymi mogą poradzić sobie nawet proste modele liniowe.


- Zawężenie analizy w **Eksperymentie 2** do populacji obciążonej wielochorobowością znacząco obniżyło jakość predykcji. Wprowadzenie tego warunku spowodowało znaczny spadek rozmiaru zbiorów treningowego i testowego, co uniemożliwiło złożonej architekturze CatBoost znalezienie wzorców pozwalających na poprawną predykcję i poskutkowało spadkiem czułości do około 29%. W tych warunkach Regresja Logistyczna okazała się nieco bardziej odporna na braki danych (czułość 59%), jednak odbyło się to kosztem obniżenia ogólnej dokładności modelu.
- Eksperyment 2 obnażył również ograniczenia techniki **SMOTE** na małych zbiorach danych. Generowanie syntetycznych pacjentów na podstawie interpolacji cech zredukowało czułość modelu do bezużytecznego klinicznie poziomu 7%. Takie działanie doprowadziło zatem do całkowitego załamania granicy decyzyjnej. Przy tego typu danych lepszym podejściem okazało się zbilansowanie wag klas na poziomie funkcji kosztu (zastosowanie CatBoost Balanced).



Rysunek 8: Porównanie macierzy pomyłek wybranych modeli predykcyjnych

3.6 Istotność cech i interpretowalność (SHAP)

Podobnie jak w poprzedniej części, wykorzystano algorytm **SHAP** w celu zrozumienia procesu decyzyjnego modelu. Do analizy wykorzystano model **CatBoost z Eksperymentu 1**. Analiza wykresu wskazuje, że model opiera predykcje na klinicznie i epidemiologicznie spójnych czynnikach, a nie na całkowicie przypadkowych zależnościach w danych.



Rysunek 9: Wykres SHAP ilustrujący ważność cech w predykcji depresji

Czynniki biologiczne i zdrowotne

Najsilniejszym predyktorem okazał się wskaźnik masy ciała (BMXBMI). Wysokie wartości BMI częściej wiązały się z dodatnimi wartościami SHAP, wskazując na zwiększenie przewidywanego ryzyka depresji. Istotną rolę, co ciekawe, odgrywała także płeć (RIAGENDR) — płeć żeńska zwiększała ryzyko wystąpienia depresji. Model wskazał również na istotny wpływ młodszego wieku (RIDAGEYR), co może być związane z częstszym raportowaniem objawów depresyjnych przez młodszych dorosłych.

Uwarunkowania socjoekonomiczne

Wysoko w rankingu ważności znalazły się zmienne związane z sytuacją społeczną i ekonomiczną, np. stan cywilny (DDMARTL). Analizując dane ze zbioru NHANES, można zauważyć, że najwyższy odsetek depresji obserwowano wśród osób owdowiałych oraz


rozwiedzionych (ok. 17-18%), natomiast najniższy w grupie pozostającej w małżeństwie (6,1%). Potwierdza to zatem wpływ tej cechy na decyzję modelu. Podobny kierunek zależności odnotowano dla poziomu wykształcenia (DMDEDUC2) oraz wskaźnika dochodu do granicy ubóstwa (INDFMPIR). Silny wpływ zaobserwowano również dla zmiennych związanych z bezpieczeństwem żywnościowym (FSD032A, FSD032B). Odpowiedzi wskazujące na trudności w dostępie do żywności (wyższe wartości) wiązały się z wyższymi wartościami SHAP.

Styl życia i używki

Model wskazał na dodatni wpływ palenia papierosów (SMQ020) oraz historii używania substancji psychoaktywnych (DUQ240) na przewidywane ryzyko depresji. Potwierdziły to statystyki wyciągnięte bezpośrednio ze zbioru danych, gdzie w grupie palących odsetek depresji wynosił 14,58% wobec 6,34% u osób niepalących, a dla osób używających substancji psychoaktywnych przekraczał 18%.

Interpretacja lokalna (Waterfall Plot)

Zinterpretowano również pojedynczą predykcję dla poprawnie sklasyfikowanego przypadku pozytywnego (wykres kaskadowy). Wynik modelu został zwiększony przede wszystkim przez spożywanie narkotyków, bardzo wysokie BMI, trudności z bezpieczeństwem żywnościowym, deklarowane palenie papierosów oraz płeć żeńską. Pokazuje to, że ostateczna predykcja wynikała z jednoczesnego działania wielu czynników ryzyka.



Rysunek 10: Wyjaśnienie predykcji dla pojedynczego pacjenta

3.7 Weryfikacja literaturowa i analiza rozbieżności

Różnica pomiędzy najwyższym uzyskanym wynikiem (Eksperyment 1) a rezultatami z referencyjnego artykułu, w którym modele osiągnęły wskaźnik AUC rzędu 0.90 [1], skłania do analizy przyczyn tego zjawiska. Obserwowany spadek zdolności predykcyjnej prawdopodobnie nie wynika z doboru algorytmów oraz ich hiperparametrów, ale może być efektem kilku czynników:

- **Przesunięcie danych w czasie:** Modele referencyjne trenowano na danych pochodzących z lat 2009-2016. Wybrana przez nas grupa pacjentów pochodziła z cyklu 2017-2018. Oznacza to, że potencjalnie funkcjonowała w odmiennych warunkach społeczno-gospodarczych. Pozwala to wnioskować, że modele predykcyjne bazujące na zmiennych ankietowych i majątkowych mogą starzeć się znacznie szybciej, niż klasyczne modele fizjologiczne, takie jak wykorzystane przy diagnozie cukrzycy.
- **Ograniczenia w inżynierii cech:** Istotny wpływ na różnicę w skuteczności mogło mieć również nieidealne odtworzenie środowiska analitycznego z artykułu. Autorzy, oprócz bezpośrednich atrybutów pozyskanych z bazy danych NHANES, użyli również skomplikowane, syntetyczne wskaźniki (np. matematycznie wyli-

czany wskaźnik otyłości metabolicznej METS), których brak w naszym zbiorze mógł pozbawić algorytmu ważnej wiedzy medycznej.

- **Różnice w wolumenie próby badawczej:** Oryginalne badanie opierało się na agregacji aż czterech cykli NHANES oraz danych zebranych w aż siedmiu latach, co dostarczyło modelom znacznie większy, bogatszy materiał treningowy. Próba wyodrębnienia analogicznych wzorców z zaledwie jednego rocznika natrafiła na naturalną barierę.

Podsumowując, rozbieżność względem literatury stanowi cenną obserwację. Bezpośrednie przenoszenie założeń na nowe zbiory danych jest wrażliwe na kontekst czasowy oraz dokładność odtworzenia inżynierii cech.

4 Wnioski końcowe

4.1 Wnioski z Części I

1. **Wysoka wiarygodność modelu:** Uzyskane wyniki AUC na poziomie 0.93 świadczą o bardzo wysokiej zdolności predykcyjnej modeli. Połączenie danych demograficznych z wynikami badań krwi pozwala na skuteczną identyfikację osób zagrożonych cukrzycą.
2. **Zgodność medyczna:** Analiza wartości SHAP potwierdziła, że modele kierują się przesłankami zgodnymi z wiedzą medyczną – kluczowym wskaźnikiem jest poziom glukozy, wspierany przez wiek i wskaźniki otyłości (BMI, obwód pasa).
3. **Optymalizacja progu decyzyjnego:** Standardowy próg 0.5 jest dobrym kompromisem, jednak w zastosowaniach medycznych (badania przesiewowe) zaleca się stosowanie progu w okolicach 0.35. Pozwala to na wychwycenie większej liczby osób chorych (wyższy *Recall*), co jest ważniejsze niż uniknięcie fałszywych alarmów.
4. **Wybór architektury:** Modele gradientowe (LightGBM, XGBoost) okazały się bardziej stabilne i precyzyjne od klasycznej regresji logistycznej, lepiej radząc sobie z eliminacją wyników fałszywie dodatnich przy zachowaniu wysokiej ogólnej skuteczności.
5. **Znaczenie SMOTE:** Technika oversamplingu była niezbędna do poprawnego wytrenowania modeli na niezbalansowanym zbiorze NHANES, pozwalając modelom nauczyć się rzadkich przypadków zachorowań.

4.2 Wnioski z Części II

1. **Wymóg doboru technik balansowania do natury danych:** Projekt udowodnił, że w uczeniu maszynowym nie istnieje jeden uniwersalny schemat przetwarzania. Zastosowanie podejścia ze SMOTE skutecznie wspierało analizę ciągłych parametrów laboratoryjnych pacjentów (Część I), ale w problemie z kategorycznymi danymi ankietowymi (Część II) całkowicie zawiódł.
2. **Zjawisko głodzenia modelu:** Porównanie populacji ogólnej z grupą obciążoną wielochorobowością pokazało zagrożenia wynikające z filtrowania danych. Choć warunek wielochorobowości miał uzasadnienie medyczne, na poziomie pojedynczego cyklu bazy NHANES doprowadził do znacznego zmniejszenia rozmiaru zbioru testowego. Uniemożliwiło to algorytmom odnalezienie powtarzalnych wzorców, obniżając czułość predykcji do krytycznych poziomów.
3. **Wysoka użyteczność modeli bazowych:** Analiza udowodniła, że bardziej skomplikowana architektura nie zawsze gwarantuje wyższą skuteczność na danych medycznych. W danych, w których występują wyraźne, liniowe zależności (np. im wyższy wskaźnik biedy, tym większe ryzyko depresji), Regresja Logistyczna potrafi przewyższyć algorytmy drzewiaste pod kątem czułości. Natomiast algorytm CatBoost wyróżniał się wyższą precyzją i ogólną zdolnością separacji klas (AUC). Dodatkowo jego zdolność do obsługi zmiennych kategorycznych i braków danych pozwala na bezpieczniejszą pracę z wynikami ankiet.
4. **Zgodność predykcji z realiami medycznymi i socjologicznymi:** Wykorzystanie algorytmu SHAP pozwoliło na zrozumienie procesu decyzyjnego. Analiza potwierdziła, że przy diagnozowaniu depresji algorytm największą wagę przypisuje czynnikom środowiskowym zamiast danym laboratoryjnym. Porównanie decyzji modelu z rzeczywistymi statystykami NHANES dowodzi, że algorytm trafnie odzwierciedla faktyczny wpływ takich zjawisk jak brak bezpieczeństwa żywnościowego, ubóstwo, samotność czy stosowanie używek na zdrowie psychiczne pacjentów.

Bibliografia

- [1] Ye, K., Peng, H., Zhang, X., Wang, L., Yang, J., & Hu, M. (2024). *Machine Learning-Based Prediction of Depression Risk in Patients with Multimorbidity: A Study Using NHANES Data from 2009-2016*. Research Square (Preprint). DOI: 10.21203/rs.3.rs-5430116/v1.
- [2] Kroenke, K., Spitzer, R. L., & Williams, J. B. (2001). *The PHQ-9: validity of a brief depression severity measure*. Journal of General Internal Medicine, 16(9), 606–613.